Masked Modeling em Deep Learning

Frederico Maciel de Mello | Luan Pedro de Souza Silva

Seminário, 16/10

Roteiro

- O problema: aprender representações com conteúdo incompleto
- Panorama: BERT, MAE e SimMIM
- Fluxo do MAE: diagrama, equação da perda e pseudocódigo
- Arquitetura e nossa implementação
- Protocolo e orçamento de treino
- Experimento: máscara de 50% contra 75%
- Resultados, críticas e próximos passos
- Aplicações e referências

O problema

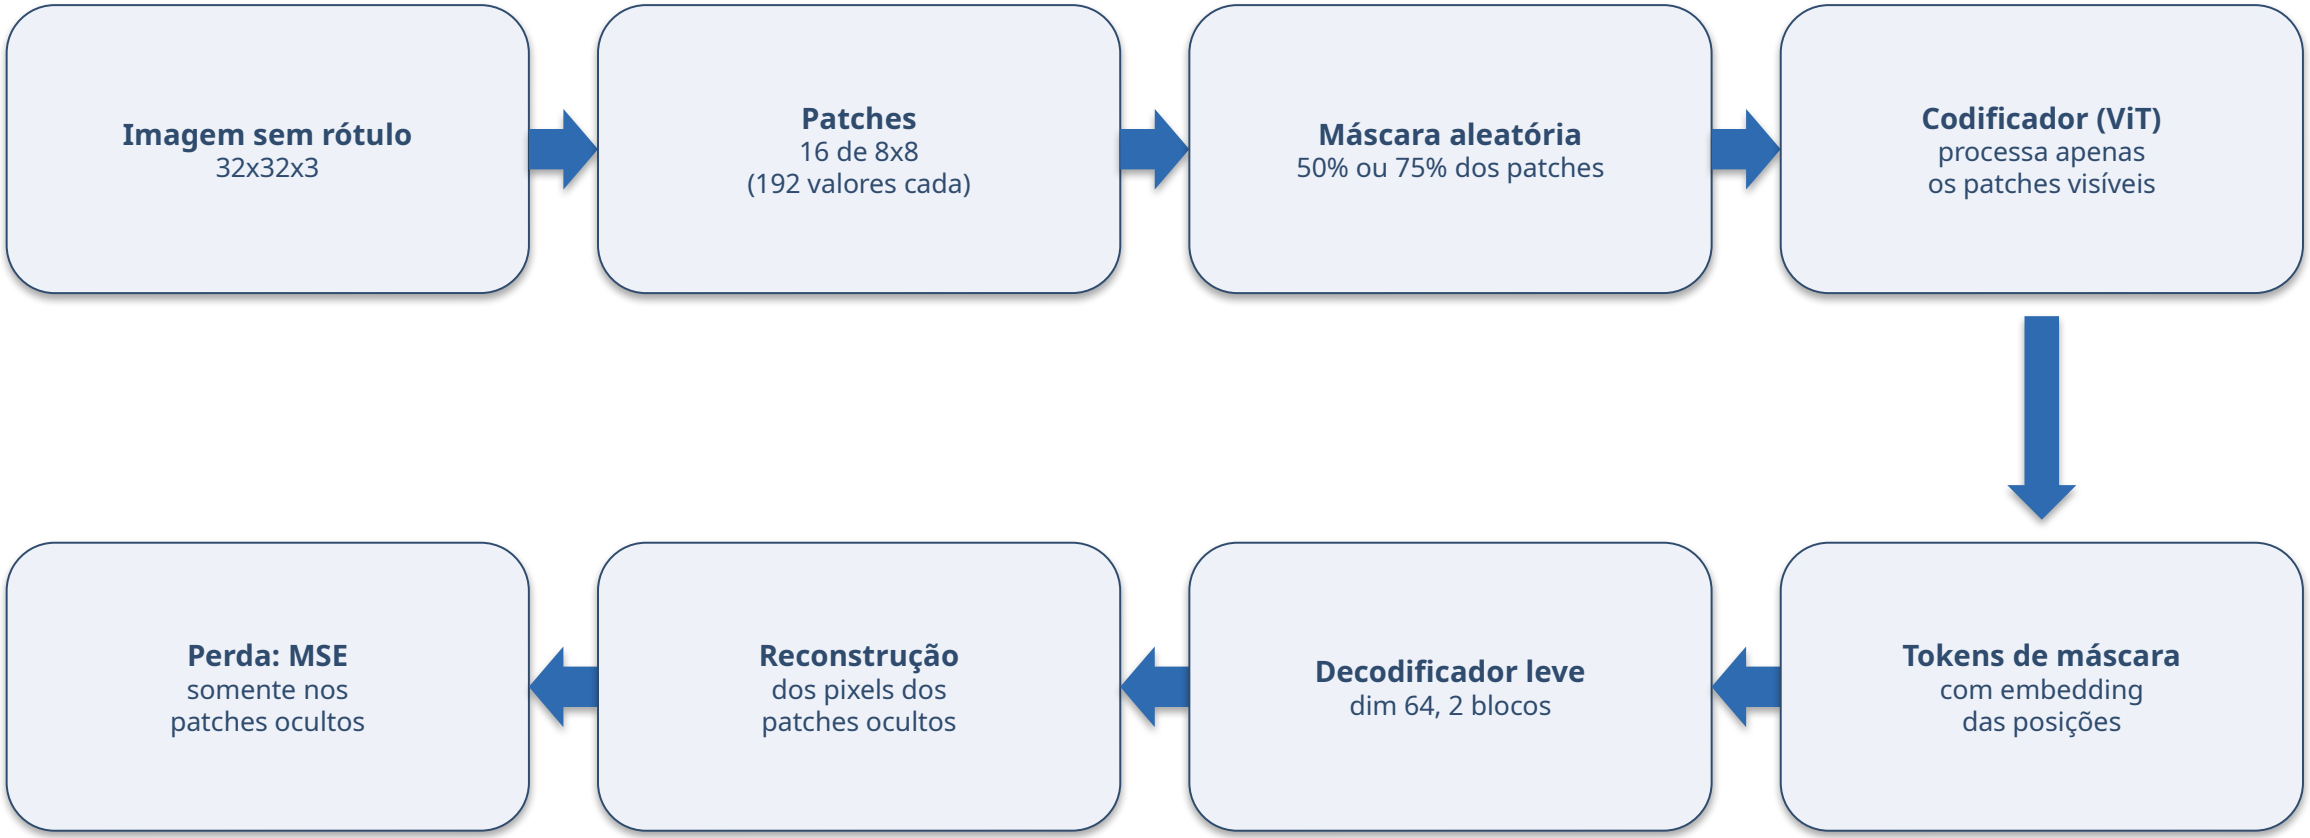
- Supervisão cara: rotular milhões de imagens é custoso
- Auto-supervisão: a própria imagem fornece o alvo
- BERT: prever palavras ocultas do texto
- Ideia do vision masking: ocultar partes da imagem e reconstruir
- A hipótese (He et al., 2022): reconstruir obrigaria o modelo a representar objetos; exigiria avaliação downstream para confirmar

Panorama: BERT, MAE e SimMIM

Dimensão	BERT	MAE	SimMIM
Modalidade	Texto (tokens discretos)	Imagem (patches de pixels)	Imagem (patches de pixels)
Alvo previsto	Palavras (tokens) ocultas	Pixels brutos dos patches ocultos	Pixels brutos dos patches ocultos
Perda	Entropia cruzada sobre os tokens ocultos	MSE nos pixels normalizados, média por patch oculto	L1 (erro absoluto) nos pixels reconstruídos
Arquitetura	Encoder Transformer único	Assimétrica: encoder pesado e decoder leve separado	Encoder único com cabeça de predição linear leve

Contraste MSE x L1: o MSE do MAE opera em pixels normalizados com média por patch e pede decoder separado; a L1 do SimMIM faz regressão direta de pixels com cabeça linear leve sobre um encoder único, que admite proporções altas de máscara também

Fluxo do MAE: da imagem à perda nos ocultos



Arquitetura assimétrica: o codificador só vê os patches visíveis e o decoder leve, descartado nas tarefas posteriores de reconhecimento (He et al., 2022)

Equação da perda e pseudocódigo do treinamento

Equação da perda (erro quadrático médio nos ocultos)
$L_{MAE} = (1/|M|) \cdot \Sigma\, i \in M\ (1/d) \cdot ||x_i - \hat{x}_i||^2$
x_i: vetor de pixels do patch i (d valores)
M: conjunto dos patches mascarados (ocultos)
$\hat{x}_i$: reconstrução do patch i produzida pelo modelo
d: número de valores de pixel por patch (192);
normaliza pela dimensão da reconstrução
média sobre $i \in M$: a perda ignora os patches visíveis

Pseudocódigo do laço de treinamento

```
1. dividir o lote em patches
2. amostrar a máscara na razão r
3. codificar somente os patches visíveis
4. decodificar com tokens de máscara e posições
5. calcular a perda somente nos patches ocultos,
normalizada por d
6. atualizar os parâmetros por retropropagação
Repetir por época sobre o conjunto de treino
```

Arquitetura e implementação

- Patchify: imagem 32x32x3 em 16 patches de 8x8 (192 valores cada)
- Encoder: somente os patches visíveis entram (ViT dim 128, 4 blocos, 4 heads)
- Decoder leve: dim 64, 2 blocos, tokens de máscara + embedding posicional
- Saída: 192 valores por patch oculto; o decoder é descartado em tarefas posteriores
- MAE próprio em PyTorch puro (sem código de terceiros), validado contra oráculo fora do pacote
- Máscara aninhada: permutação fixa por imagem com seed 42
- 50% oculta 8 patches; 75% oculta 12 (todos os da 50% também)

Protocolo e orçamento de treino

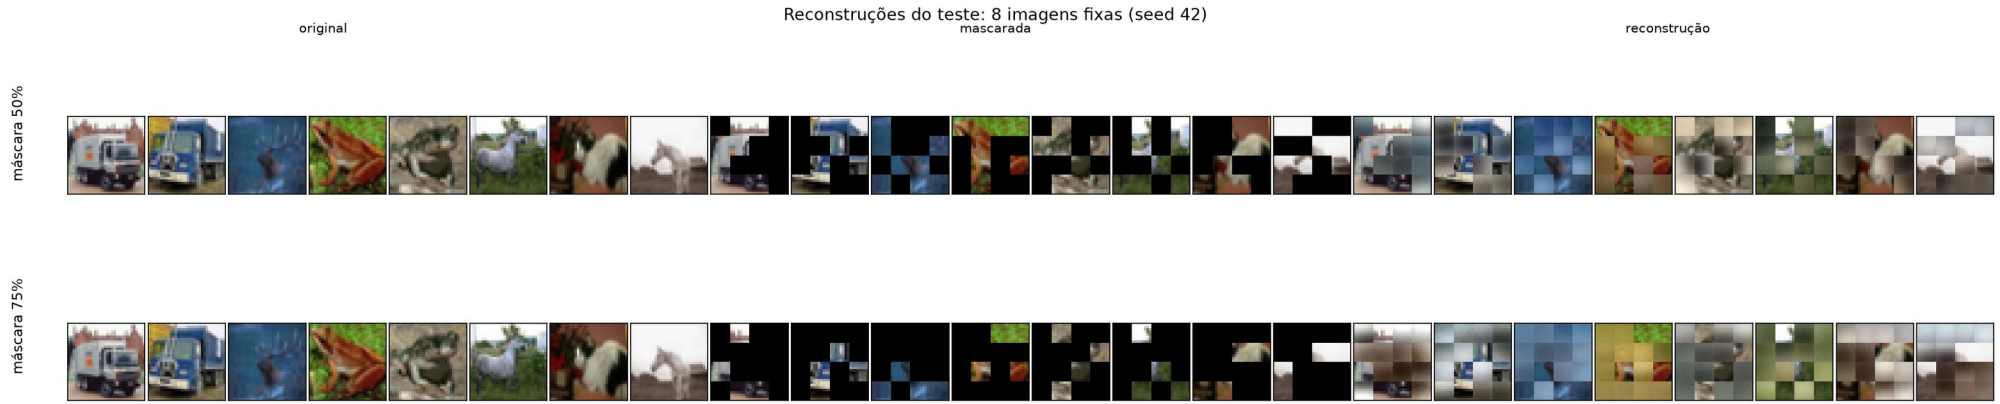
- CIFAR-10 verificado por md5 antes de qualquer uso
- Subset seed 42, balanceado: 500 treino, 100 validação e 100 teste por classe
- Validação disjunta do treino; teste sai do split oficial e é usado só no fim
- Métrica: MSE nos patches ocultos do conjunto de teste

Experimento: máscara de 50% contra 75%

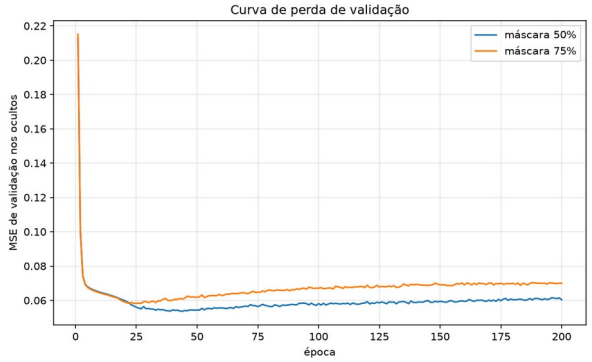
- Mesmo treino nas duas condições: 200 épocas, batch 256, lr 3.0e-04 (AdamW)
- O custo computacional por época diverge: a 75% o encoder vê 4 tokens, a 50% vê 8
- Tempo medido por época (na condição 75%): 0.58 s
- Orçamento previsto: 30 minutos para as duas condições somadas
- MSE de teste nos ocultos: 50% = 0.0608 | 75% = 0.0717

Resultados: reconstruções e curva de perda

Reconstruções: 8 imagens fixas do teste (seed 42)



Curva de perda de validação: MSE nos patches ocultos por época



Esquerda: original, mascarada e reconstrução por condição; direita: as duas condições no mesmo eixo

Resultados, críticas e próximos passos

- 75% oculta mais e é mais difícil: MSE 0.0717 contra 0.0608 a 50% (+17.8%)
- Épocas, batch e lr igualados; a computação por época diverge (4 contra 8 tokens no encoder)
- Máscara aninhada isola o efeito da taxa: os patches ocultos a 50% também estão a 75%
- Evidência desta configuração: semente única 42, teste fixo de 1.000 imagens e máscara aninhada
- Não generalizar: repetir com mais sementes e avaliar downstream antes de concluir
- Qualidade visual da reconstrução não é prova de representações melhores
- Dataset pequeno e didático: qualidade absoluta menor que a do paper
- Linear probing e classificação downstream fora do escopo; próximo passo: linear probing em mais sementes

Aplicações e referências

Aplicações das representações aprendidas:
BERT: compreensão de linguagem (busca, classificação e diálogo)
MAE: classificação, detecção e segmentação de imagens
SimMIM: classificação, detecção e segmentação em imagens

Referências:
Devlin, J.; Chang, M.; Lee, K.; Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL-HLT.
He, K.; Chen, X.; Xie, S.; Li, Y.; Dollár, P.; Girshick, R. (2022). Masked Autoencoders Are Scalable Vision Learners. CVPR.
Xie, Z.; Zhang, Z.; Lin, Y.; Bian, J.; Lin, L.; Zeng, D. (2022). SimMIM: A Simple Framework for Masked Image Modeling. CVPR.
Krizhevsky, A.; Nair, V.; Hinton, G. (2009). CIFAR-10 (Canadian Institute for Advanced Research). Fonte dos dados, verificado por md5.