Masked Modeling em Deep Learning

Frederico Maciel de Mello | Luan Pedro de Souza Silva

Seminário, 16/10

Roteiro

- O problema: aprender representações com conteúdo incompleto
- Panorama: BERT, MAE e SimMIM
- Arquitetura de um Masked Autoencoder
- Nossa implementação: patches, máscara aninhada, perda
- Protocolo e orcamento de treino
- Experimento: máscara de 50% contra 75%
- Resultados, críticas e próximos passos

O problema

- Supervisão cara: rotular milhões de imagens é custoso
- Auto-supervisão: a própria imagem fornece o alvo
- BERT: prever palavras ocultas do texto
- Ideia do vision masking: ocultar partes da imagem e reconstruir
- A hipótese (He et al., 2022): reconstruir obrigaria o modelo a representar objetos; exigiria avaliação downstream para confirmar

Panorama: BERT, MAE e SimMIM

- BERT (2018): mascarar tokens de texto e prever os ocultos
- MAE (He et al., 2022): patches ocultos, encoder assimétrico, decoder leve
- SimMIM (2022): mascarar pixels brutos com decoder simples
- Diferença chave: o quanto se pode ocultar (75% funciona no MAE)

Arquitetura do MAE

- Patchify: imagem 32x32x3 em 16 patches de 8x8 (192 valores cada)
- Encoder: somente os patches visíveis entram (ViT dim 128, 4 blocos, 4 heads)
- Decoder leve: dim 64, 2 blocos, tokens de máscara + embedding posicional
- Saída: 192 valores por patch oculto (a imagem completa)
- Perda: MSE somente nos patches ocultos, pixels brutos em [0,1]

Nossa implementação

- MAE próprio em PyTorch puro (sem código de terceiros)
- Máscara aninhada: permutação fixa por imagem com seed 42
- 50% oculta 8 patches; 75% oculta 12 (todos os da 50% também)
- Validação contra o oráculo vit-pytorch em testes fora da entrega

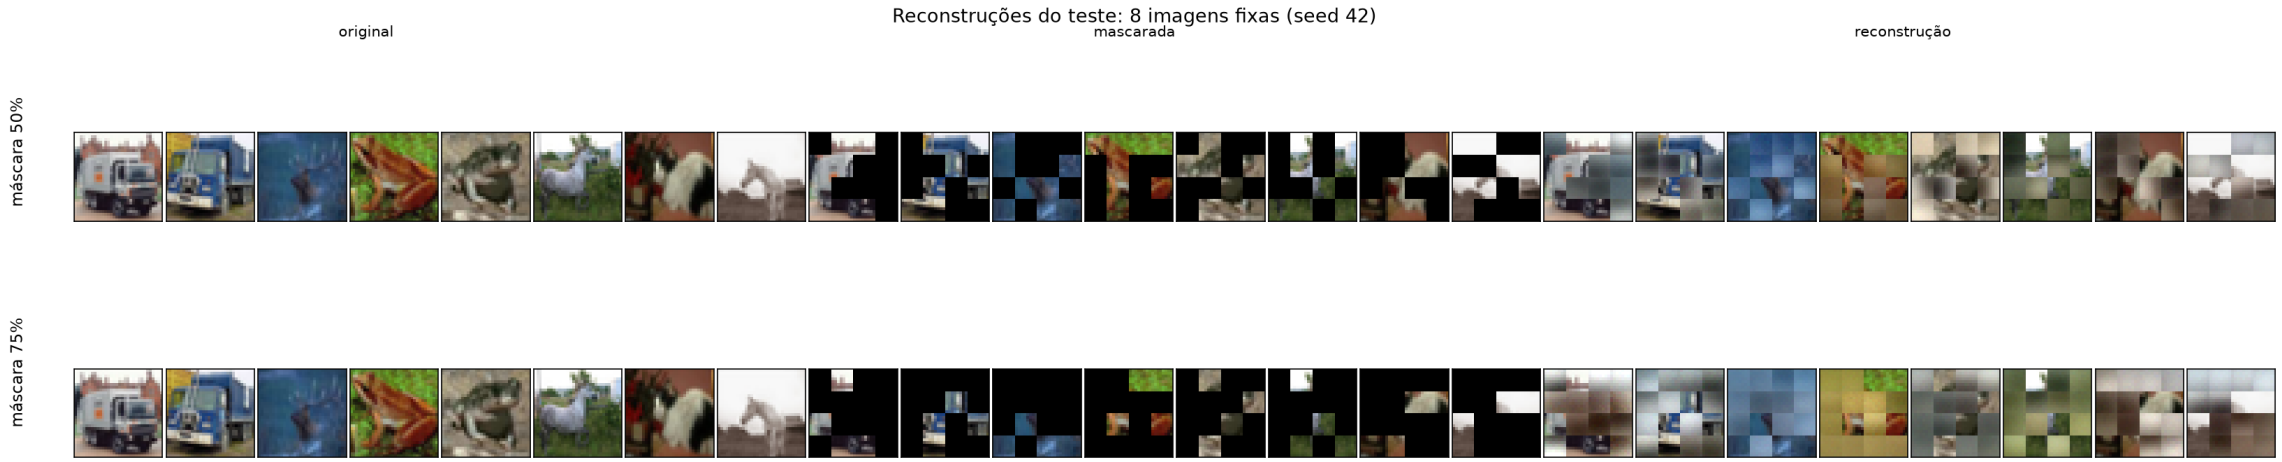
Dados e protocolo

- CIFAR-10 verificado por md5 antes de qualquer uso
- Subset seed 42, balanceado: 500 treino, 100 validação e 100 teste por classe
- Validação disjunta do treino; teste sai do split oficial e é usado só no fim
- Métrica: MSE nos patches ocultos do conjunto de teste

Experimento: máscara de 50% contra 75%

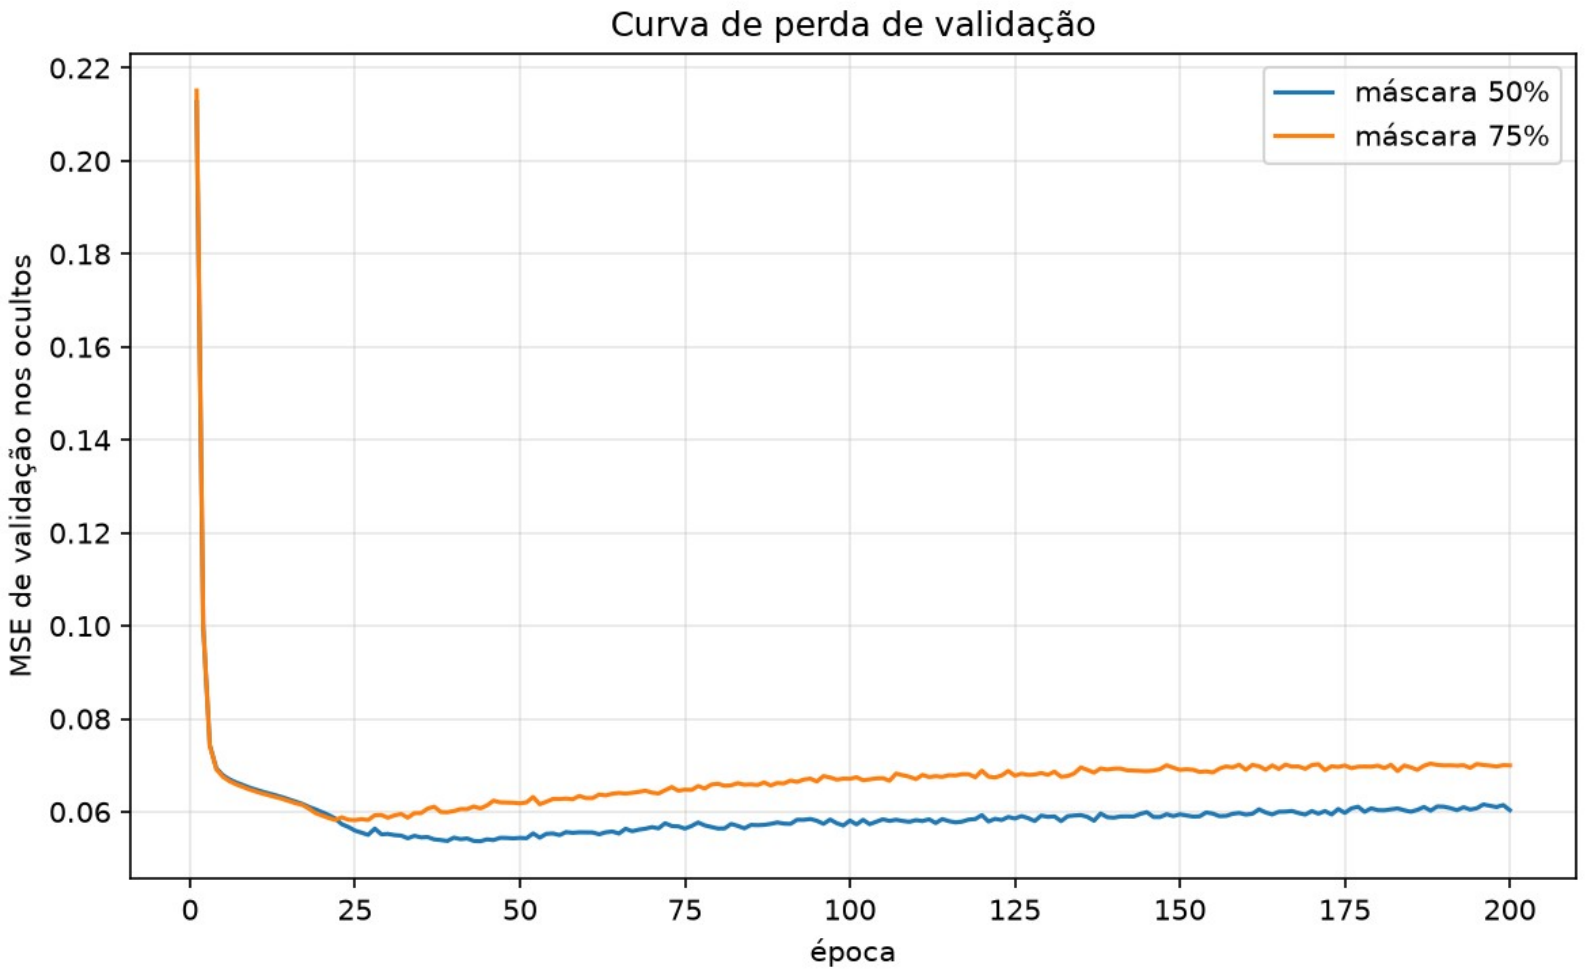
- Mesmo treino nas duas condições: 200 épocas, batch 256, lr 3.0e-04 (AdamW)
- O custo computacional por época diverge: a 75% o encoder vê 4 tokens, a 50% vê 8
- Tempo medido por época na RTX 3050 (na condição 75%): 0.58 s
- Orçamento previsto: 30 minutos para as duas condições somadas
- MSE de teste nos ocultos: 50% = 0.0608 | 75% = 0.0717

Resultados: reconstruções



8 imagens fixas do teste (seed 42): original, mascarada e reconstrução por condição

Resultados: curva de perda de validação



MSE de validação nos patches ocultos por época

Lendo os números

- 75% oculta mais e é mais difícil: MSE 0.0717 contra 0.0608 a 50% (+17.8%)
- Épocas, batch e taxa de aprendizado foram igualados; a quantidade de computação por época diverge (4 contra 8 tokens no encoder)
- A diferença principal entre condições vem da taxa de ocultação
- Máscara aninhada isola o efeito da taxa (mesmos patches ocultos a 50%)
- Semente única 42: comparação determinística, mas repetição com mais sementes é necessária

Limitações e próximos passos

- Dataset pequeno e didático: qualidade absoluta é menor que a do paper
- Linear probing e classificação downstream: fora do escopo deste trabalho
- Próximo passo: avaliar representações com linear probing em mais sementes
- Referência: He et al. (2022), Masked Autoencoders Are Scalable Vision Learners