Masked Modeling em Deep Learning

Frederico Maciel de Mello | Luan Pedro de Souza Silva

Seminário, 16/10

O que é Masked Modeling

- Estratégia de aprendizado em que parte dos dados de entrada é propositalmente ocultada (mascarada)
- O modelo é treinado para prever ou reconstruir a informação ausente
- Ideia-chave: o próprio dado fornece a supervisão
- A parte original funciona como referência para verificar o que o modelo previu ou reconstruiu
- Quatro etapas: ocultar uma parte da entrada, usar o visível como contexto,
- prever ou reconstruir o conteúdo mascarado e aprender representações úteis dos dados

Por que usar: motivações

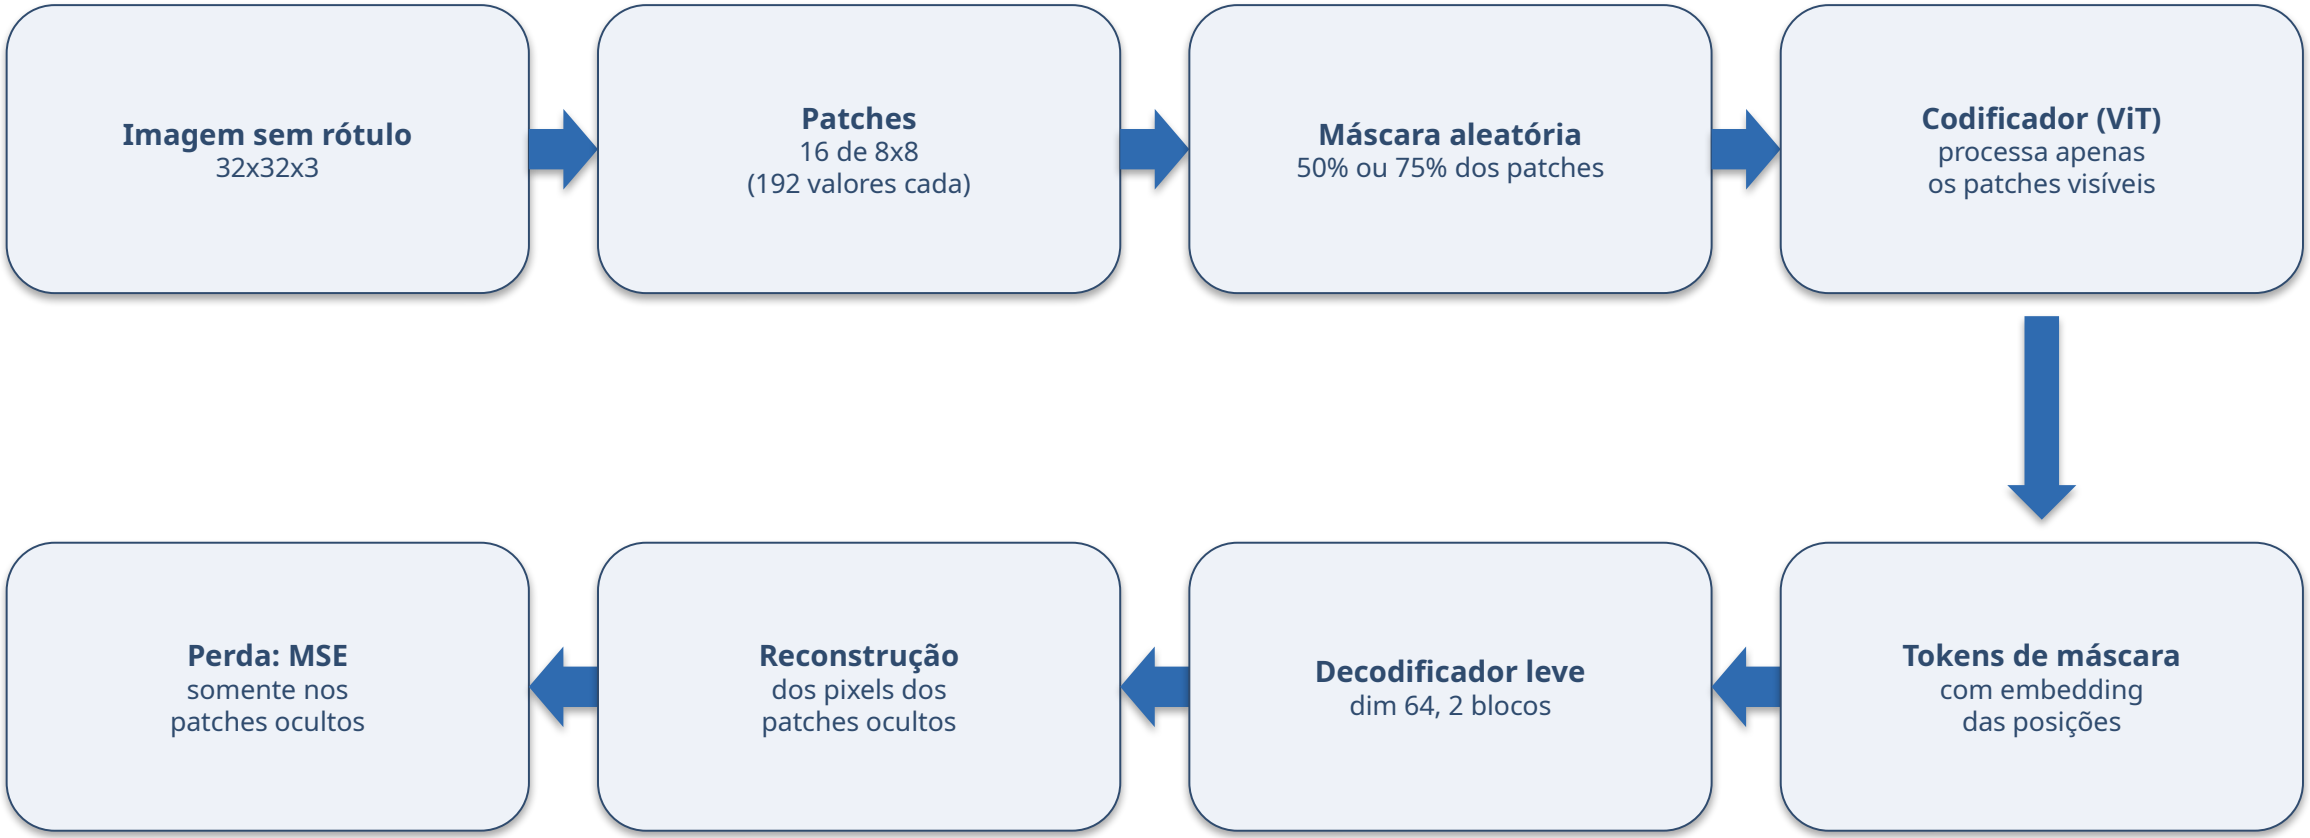
- Treino de deep learning depende de grandes quantidades de dados rotulados, caros e demorados de obter
- Masked modeling aproveita dados não rotulados: a tarefa de aprendizado nasce do próprio dado
- Reduz a dependência de dados rotulados
- Aprende representações relevantes dos dados
- Explora o contexto e as relações entre as partes da entrada
- Serve de pré-treinamento para modelos adaptados a outras tarefas depois

Panorama: BERT, MAE e SimMIM

Dimensão	BERT	MAE	SimMIM
Modalidade	Texto (tokens discretos)	Imagem (patches de pixels)	Imagem (patches de pixels)
Alvo previsto	Palavras (tokens) ocultas	Pixels brutos dos patches ocultos	Pixels brutos dos patches ocultos
Perda	Entropia cruzada sobre os tokens ocultos	MSE nos pixels normalizados, média por patch oculto	L1 (erro absoluto) nos pixels reconstruídos
Arquitetura	Encoder Transformer único	Assimétrica: encoder pesado e decoder leve separado	Encoder único com cabeça de predição linear leve

Contraste MSE x L1: o MSE do MAE opera em pixels normalizados com média por patch e pede decoder separado; a L1 do SimMIM faz regressão direta de pixels com cabeça linear leve sobre um encoder único, que admite proporções altas de máscara também

Fluxo do MAE: da imagem à perda nos ocultos



Arquitetura assimétrica: o codificador só vê os patches visíveis e o decoder leve, descartado nas tarefas posteriores de reconhecimento (He et al., 2022)

Equação da perda e pseudocódigo do treinamento

Equação da perda (erro quadrático médio nos ocultos)
$L_{MAE} = (1/|M|) \cdot \Sigma\, i \in M\ (1/d) \cdot ||x_i - \hat{x}_i||^2$
x_i: vetor de pixels do patch i (d valores)
M: conjunto dos patches mascarados (ocultos)
$\hat{x}_i$: reconstrução do patch i produzida pelo modelo
d: número de valores de pixel por patch (192);
normaliza pela dimensão da reconstrução
média sobre $i \in M$: a perda ignora os patches visíveis

Pseudocódigo do laço de treinamento

```
1. dividir o lote em patches
2. amostrar a máscara na razão r
3. codificar somente os patches visíveis
4. decodificar com tokens de máscara e posições
5. calcular a perda somente nos patches ocultos,
normalizada por d
6. atualizar os parâmetros por retropropagação
Repetir por época sobre o conjunto de treino
```

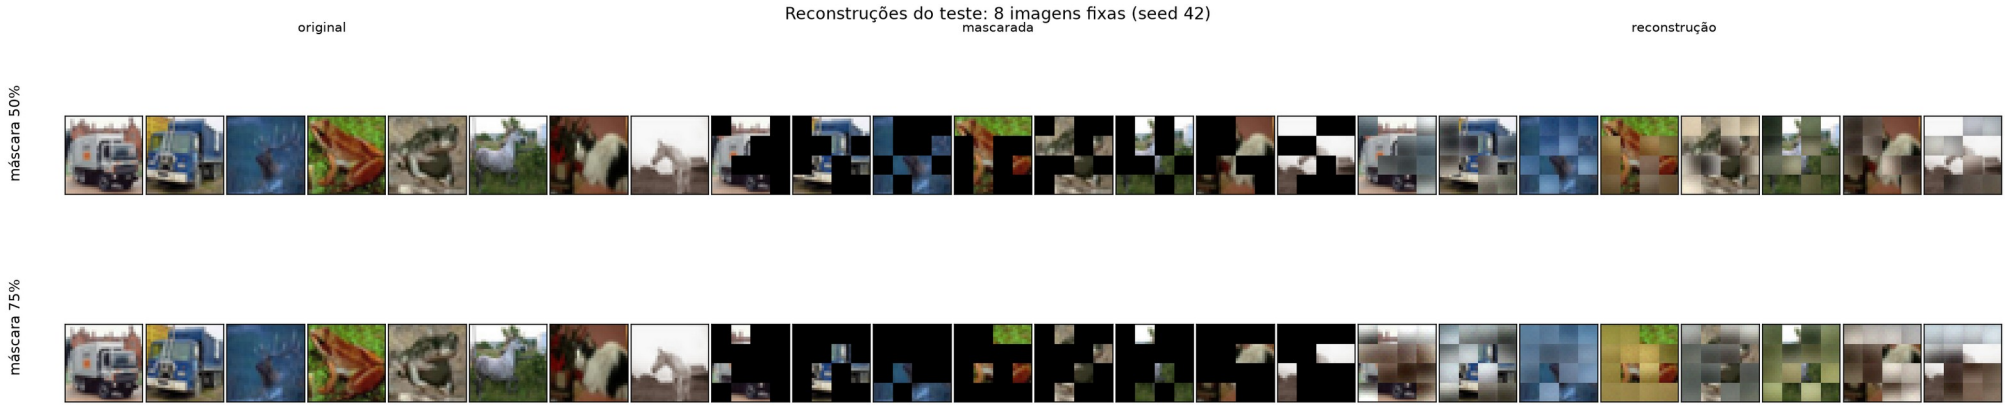
Experimento próprio no CIFAR-10

MAE próprio, escrito do zero em PyTorch puro (sem código de terceiros)
Mesmo protocolo nas duas condições: 200 épocas, batch 256, lr 3.0e-04 (AdamW)
Semente única 42; subset balanceado verificado por md5; teste fixo de 1.000 imagens
Máscara aninhada: os patches ocultos a 50% também estão a 75%, isolando o efeito da taxa
50% oculta 8 dos 16 patches; 75% oculta 12 (custo por época diverge: 8 contra 4 tokens no encoder)
MSE de 75% é +17.8% maior que o de 50%: nesta configuração, mascarar mais elevou o erro
Delimitação: evidência desta configuração, semente única; repetir com mais sementes e avaliar downstream antes de generalizar

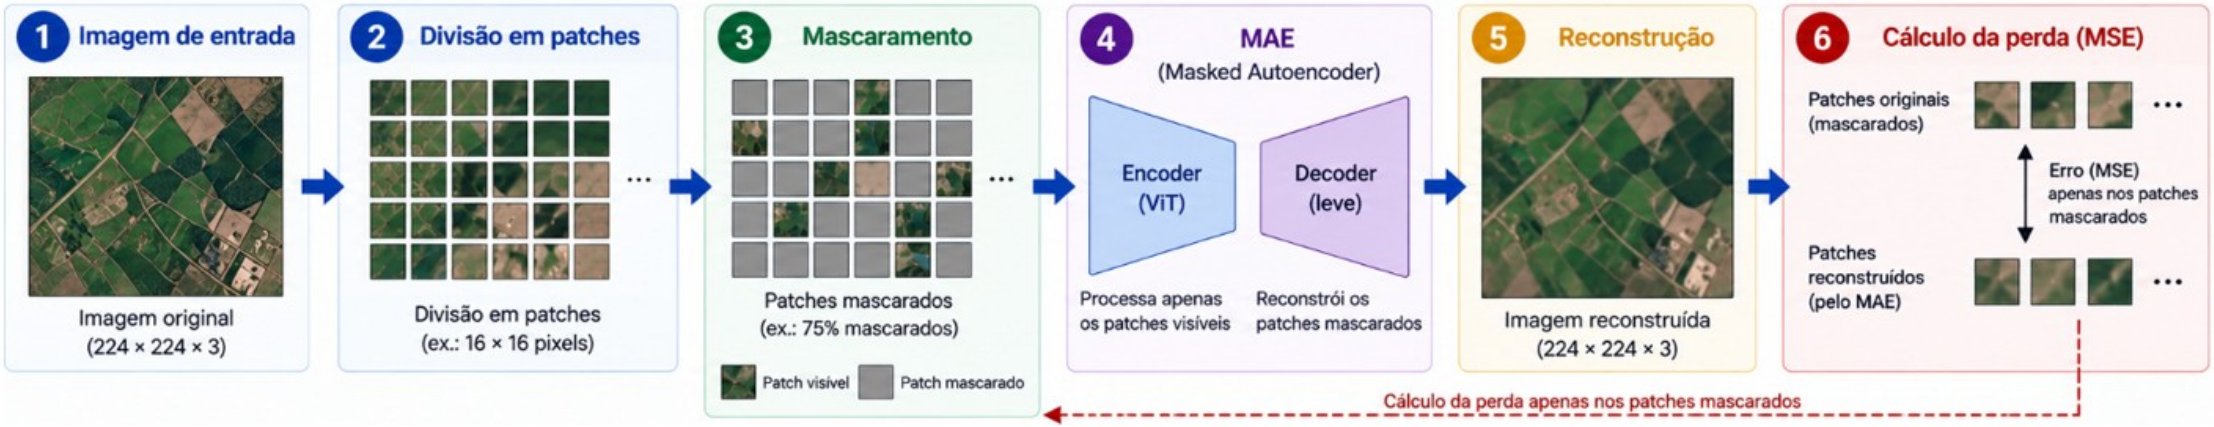
Condição	MSE de teste (ocultos)
Máscara 50%	0.0608
Máscara 75%	0.0717

Fonte: resultados/metricas.csv (semente 42)

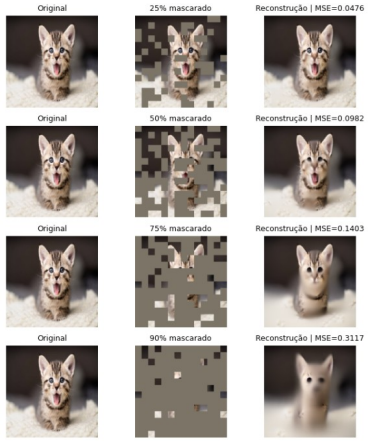
Reconstruções: 8 imagens fixas do teste (semente 42)



Experimento complementar: ViT-MAE



Mascarado e reconstruído em cada taxa



Configuração do experimento complementar:
MAE pré-treinado, arquitetura Vision Transformer (ViT)
Entrada de 224x224 pixels, patches de 16x16
Taxas avaliadas: 25%, 50%, 75% e 90%
MSEs documentados (experimento complementar):
25%: 0,0476 | 75%: 0,1403 | 90%: 0,3117
Menos informação visível torna a reconstrução mais desafiadora

Erro de reconstrução por taxa

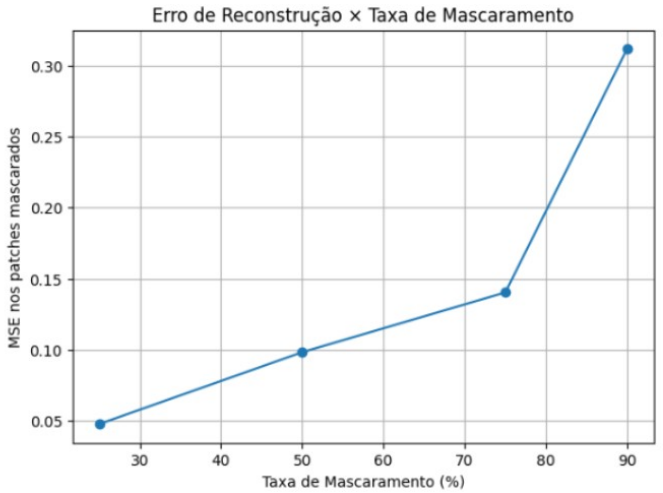


Imagem superior: fluxo do experimento com MAE pré-treinado. Experimento complementar do grupo; implementação pública: Hugging Face Transformers, ViTMAE, modelo facebook/vit-mae-base (Meta AI).
Código do experimento complementar: https://colab.research.google.com/drive/11BkUg8lzF079vWErYh5plimEVcF16gXN

Aplicações por domínio

- Pré-treinar com grandes volumes de dados não rotulados e transferir as representações
- Visão computacional: classificação, detecção de objetos, segmentação semântica, reconhecimento visual
- Imagens médicas: radiografias, tomografias e ressonâncias; pré-treinamento sem anotação; extração de características para diagnóstico
- Sensoriamento remoto: uso e cobertura do solo, detecção de mudanças, imagens de satélite, monitoramento ambiental e agrícola
- Outras modalidades: linguagem natural, vídeos, áudio e aprendizado multimodal

Pós MAE e tarefas downstream

- Pré-treinamento: o MAE usa grandes volumes de imagens não rotuladas; parte dos patches é mascarada e o modelo aprende a reconstruir
- Nesse processo, o encoder ViT aprende representações visuais das imagens
- Depois do pré-treinamento, o decoder pode ser descartado: sua função principal era auxiliar a reconstrução
- O encoder pré-treinado é reutilizado em tarefas downstream: classificação de imagens, detecção de objetos e segmentação semântica
- Uso do encoder: extrator de características ou pesos ajustados por fine-tuning para a nova tarefa
- Eco do nosso diagrama: o decoder leve sai e o encoder pesado fica

Conclusões

- Reconstruir o que foi escondido não é o objetivo final: é o mecanismo para o modelo aprender boas representações
- O mascaramento aproveita dados não rotulados, em texto (BERT) e em imagens (MAE)
- No experimento próprio, 75% mascarado errou mais que 50%: nesta configuração, mascarar mais elevou o erro (semente única 42)
- No experimento complementar com MAE pré-treinado público, as taxas maiores de mascaramento elevaram o MSE registrado no material complementar
- Leitura delimitada: qualidade visual da reconstrução não é prova de representações melhores
- Repetição com mais sementes e avaliação downstream continuam necessárias antes de generalizar

Referências

Devlin, J.; Chang, M.; Lee, K.; Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL-HLT.
Dosovitskiy, A. et al. (2021). An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale. ICLR.
He, K.; Chen, X.; Xie, S.; Li, Y.; Dollár, P.; Girshick, R. (2022). Masked Autoencoders Are Scalable Vision Learners. CVPR.
Bao, H. et al. (2022). BEiT: BERT Pre-Training of Image Transformers. ICLR.
Xie, Z.; Zhang, Z.; Lin, Y.; Bian, J.; Lin, L.; Zeng, D. (2022). SimMIM: A Simple Framework for Masked Image Modeling. CVPR.
Krizhevsky, A.; Nair, V.; Hinton, G. (2009). CIFAR-10 (Canadian Institute for Advanced Research). Fonte dos dados deste trabalho, verificado por md5.
Crédito do experimento complementar do grupo: implementação pública Hugging Face Transformers, ViTMAE, modelo facebook/vit-mae-base (Meta AI).
Código do experimento complementar: https://colab.research.google.com/drive/11BkUg8lzF079vWErYh5plimEVcF16gXN